Artistic style transfer & other advanced image editing

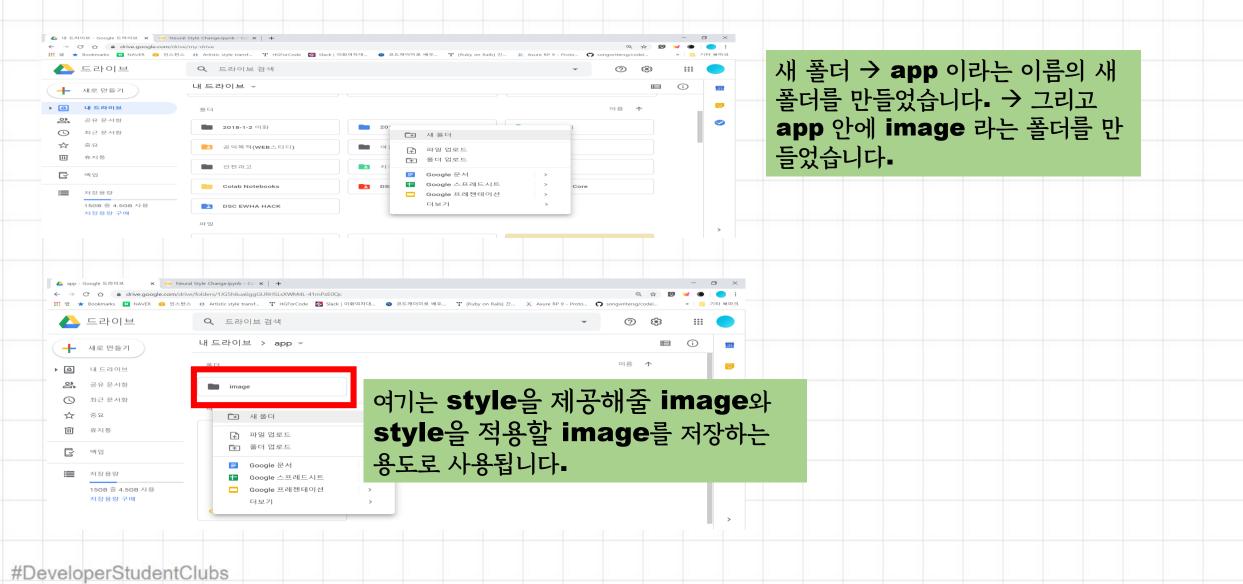
이화여자대학교 소프트웨어학부 컴퓨터공학전공 18 이하경



구글 Colab을 사용하기 위한 준비

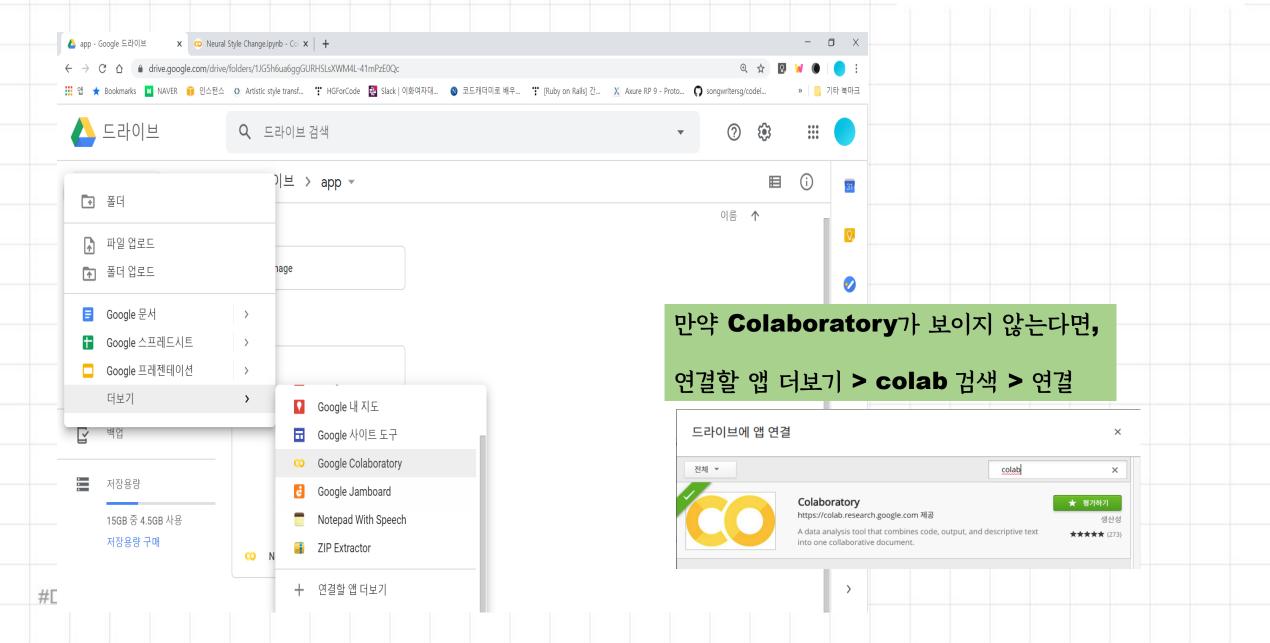


1. 구글 드라이브에서 폴더 생성



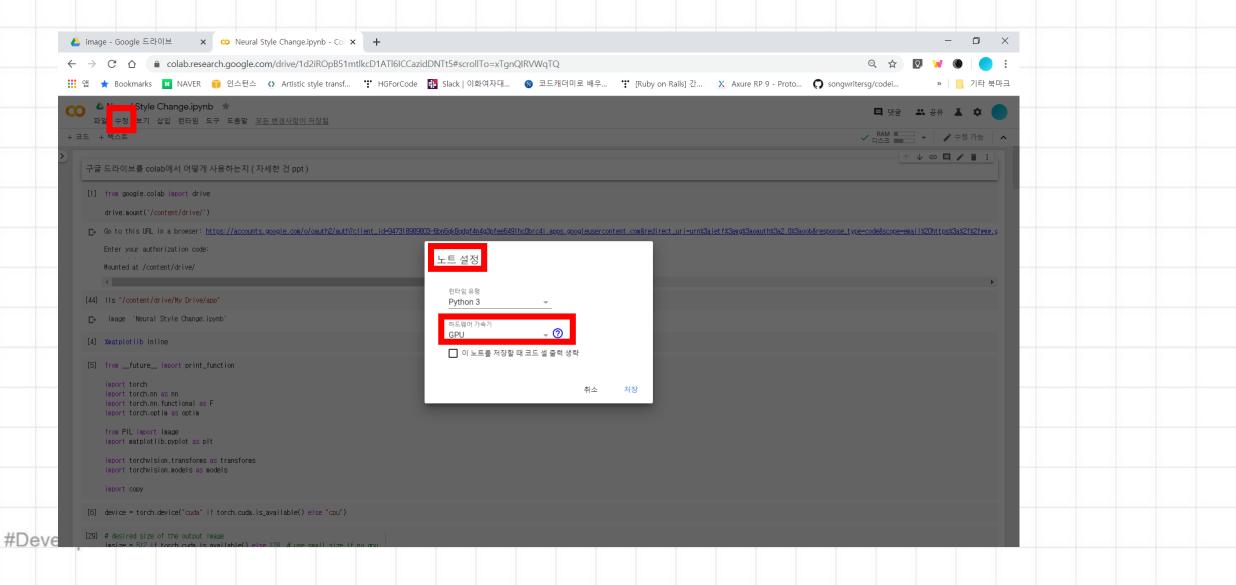
2. Colab Notebook 파일 생성





3. 무료 GPU 설정 수정 → 노트 설정 → 런타임 유형 변경 선택을 통해 하드웨어 가속기를 GPU로 변경



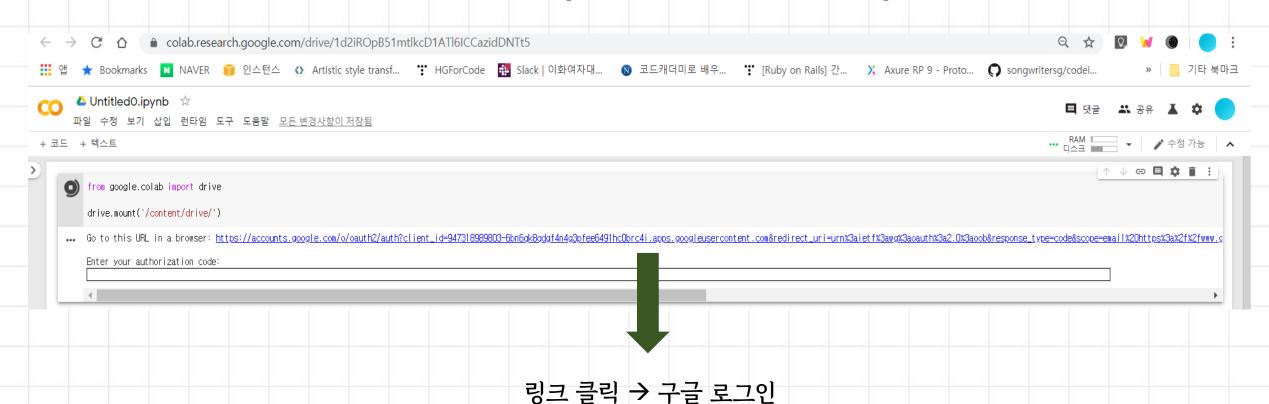


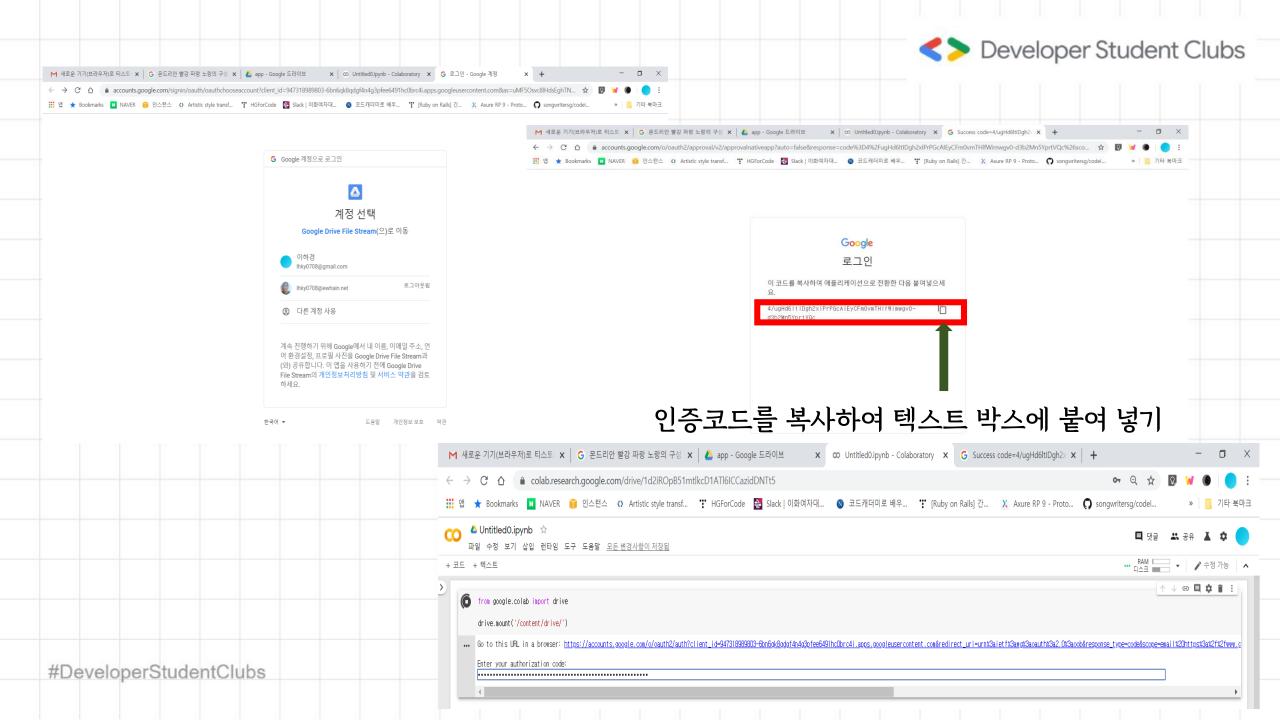
4. 구글 Colab에서 구글 Drive의 파일 가져오기 (디렉토리 설정)

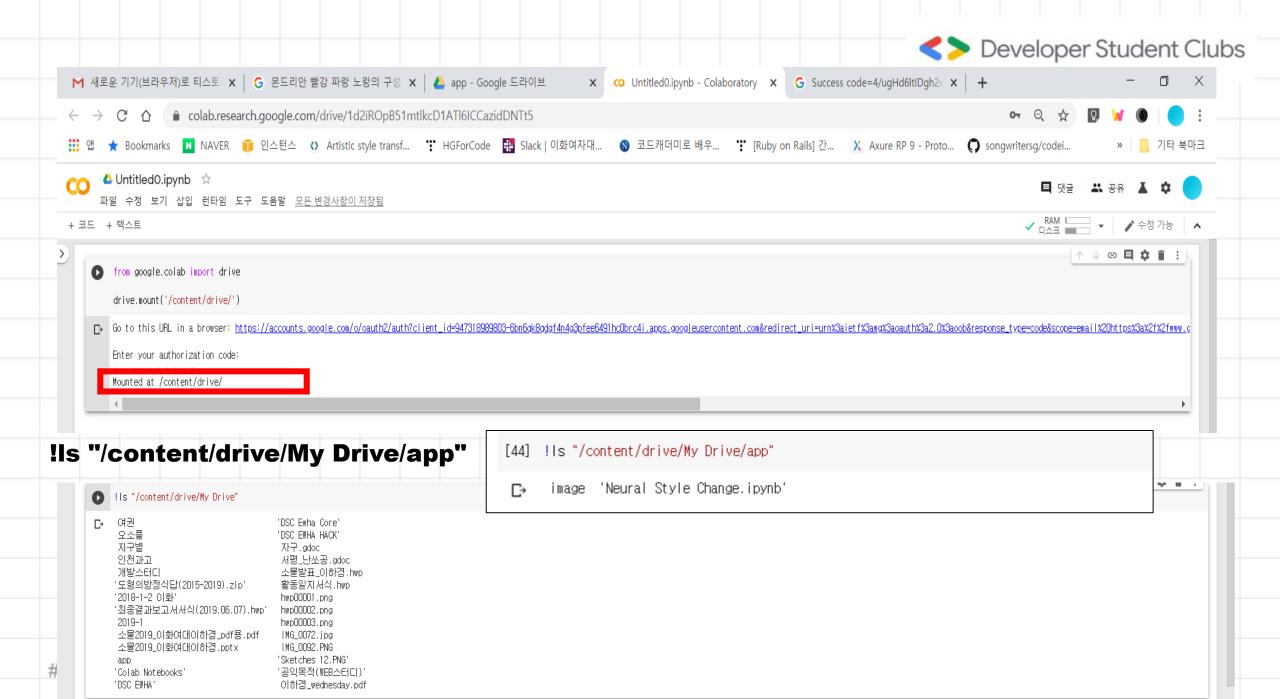
#DeveloperStudentClubs



from google.colab import drive drive.mount('/content/drive/')







본격적으로 오늘 함께 할 내용 소개



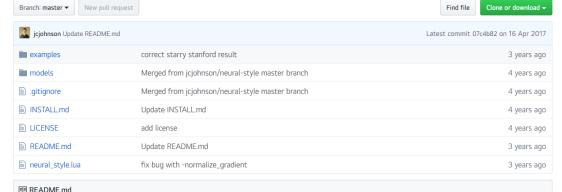






Leon A. Gatys와 Alexander S. Ecker, Matthias Bethge 가 개발한 알고리즘인 <u>Neural-Style</u> 을 직접 실습해보겠습니다!

https://github.com/jcjohnson/neural-style



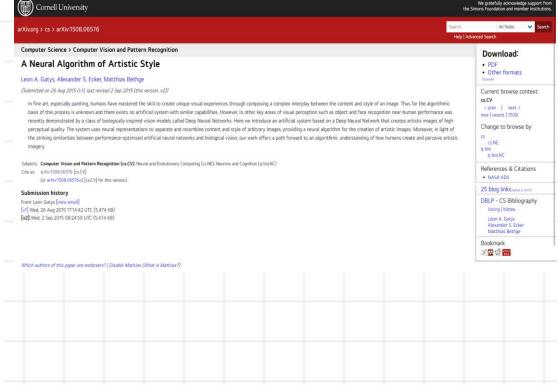
neural-style

This is a torch implementation of the paper A Neural Algorithm of Artistic Style by Leon A. Gatys, Alexander S. Ecker, and Matthias Bethge.

The paper presents an algorithm for combining the content of one image with the style of another image using convolutional neural networks. Here's an example that maps the artistic style of The Starry Night onto a night-time photograph of the Stanford campus:



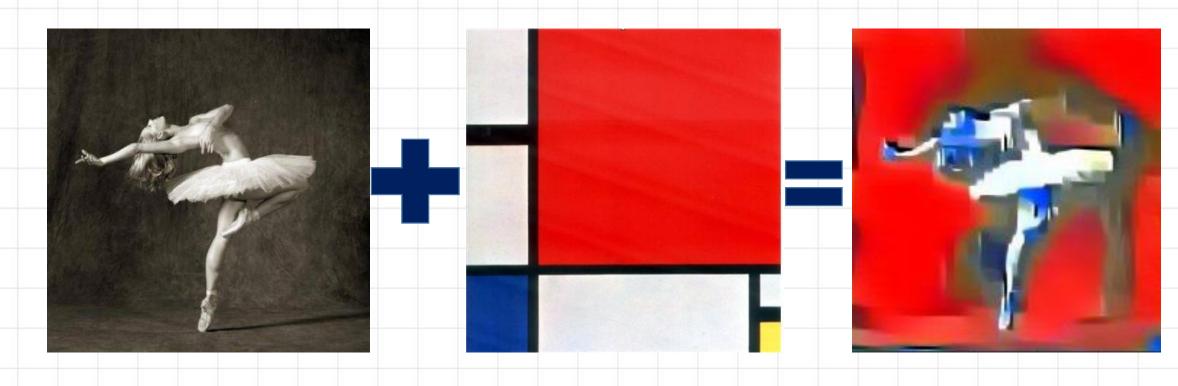






십경망 스타일(Neural-Style)

콘텐츠 이미지(예, 무용수)와 스타일 이미지(예, 몬드리안 작품) 을 입력으로 받아 콘텐츠 이미지의 모양대로 스타일 이미지의 '그리는 방식'을 이용해 그린 것처럼 결과를 내는 알고리즘



어떻게 동작할까요?? ል(◁)>>



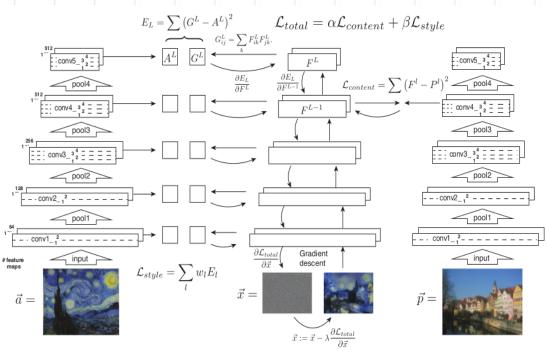
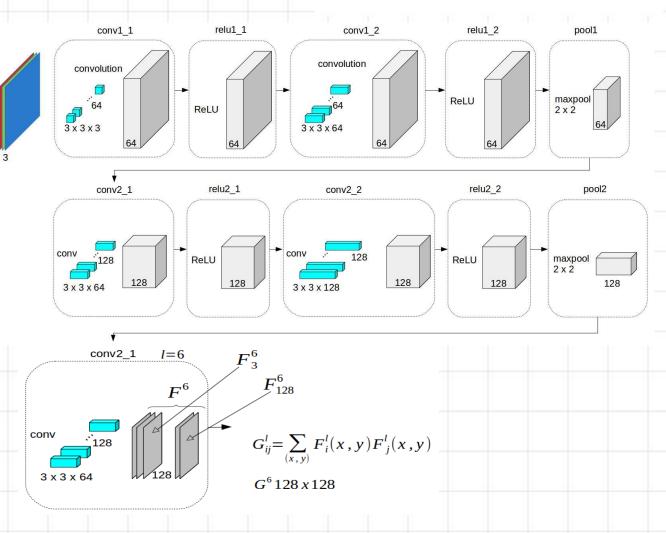


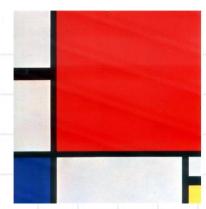
Figure 2. Style transfer algorithm. First content and style features are extracted and stored. The style image \vec{a} is passed through the network and its style representation A^l on all layers included are computed and stored (left). The content image \vec{p} is passed through the network and the content representation P^l in one layer is stored (right). Then a random white noise image \vec{x} is passed through the network and its style features G^l and content features F^l are computed. On each layer included in the style representation, the element-wise mean squared difference between G^l and A^l is computed to give the style loss \mathcal{L}_{style} (left). Also the mean squared difference between F^l and P^l is computed to give the content loss $\mathcal{L}_{content}$ (right). The total loss \mathcal{L}_{total} is then a linear combination between the content and the style loss. Its derivative with respect to the pixel values can be computed using error back-propagation (middle). This gradient is used to iteratively update the image \vec{x} until it simultaneously matches the style features of the style image \vec{a} and the content features of the content image \vec{p} (middle, bottom).



어떻게 동작할까요?? (` `(` `` ')´ `)

 D_C 콘텐츠 이미지와 스타일 이미지 간의 콘텐츠가 얼마나 차이가 있는지 측정

 D_S 콘텐츠 이미지와 스타일 이미지 간의 스타일에 서 얼마나 차이가 있는지를 측정

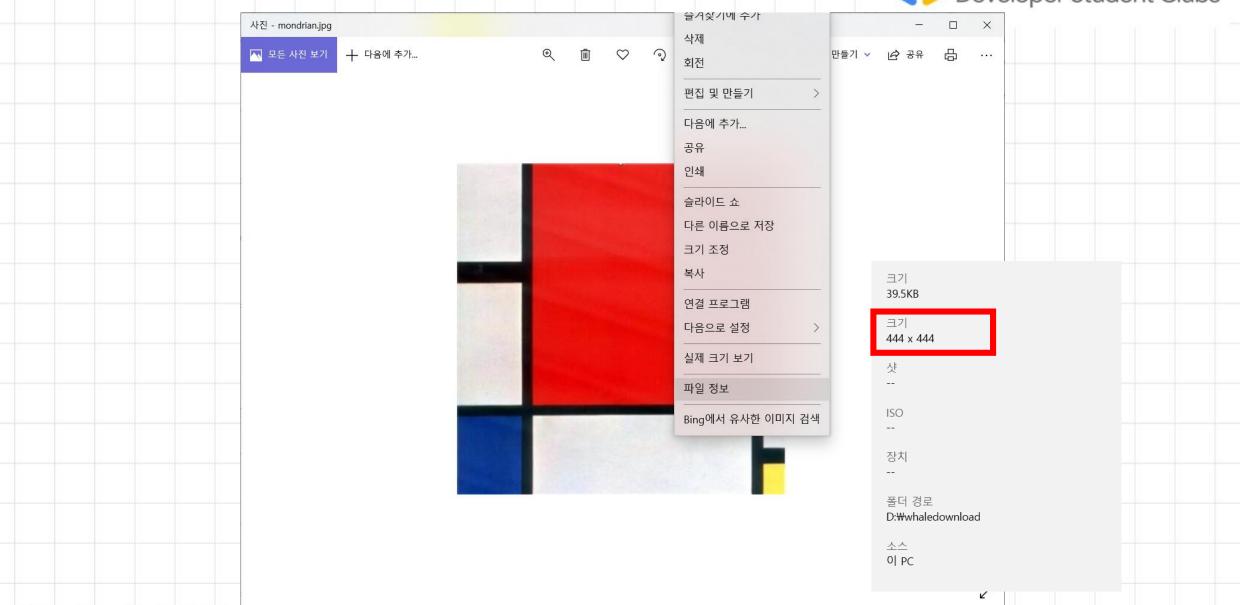


※ 따라서 콘텐츠 이미지와 스타일 이미지의 크기가 같아야 함!!

세 번째 이미지(우리가 결국 구하고자 하는 스타일 변화된 이미지)를, 콘텐츠 이미지와의 콘텐츠 거리 및 스타일 이미지와의 스타일 거리를 최소화하는 방향으로 세 번째 이미지를 변환







#DeveloperStudentClubs



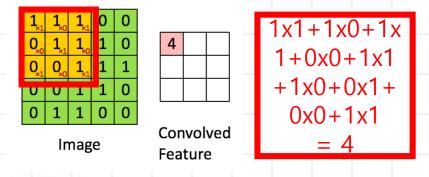
C_{nn} 사전 훈련된 깊은 합성곱 신경망 네트워크

2차원 입력 데이터(Shape: (5,5))를 1개의 필터로 합성곱 연산을 수행하고, 합성곱 처리 결과로 부터 Feature Map을 만든다.

필터는 이미지의 특징을 찾아내기 위한 공용 파라미터

CNN에서 Filter와 Kernel은 같은 의미

필터는 일반적으로 (4, 4)이나 (3, 3)과 같은 정사각 행렬로 정의

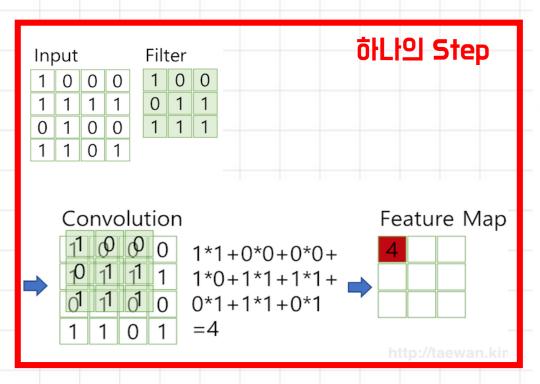


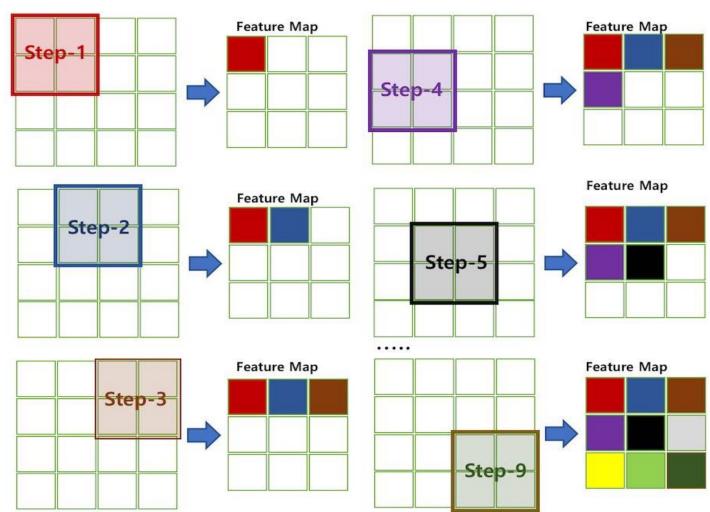
1,	1,0	1,	0	0
O _{×0}	1 _{×1}	1,0	1	0
0 _{×1}	0,0	1,	1	1
0	0	1	1	0
0	1	1	0	0

Image

4	

Convolved Feature





C_{nn} 사건 훈련된 깊은 합성곱 신경망 네트워크

X, Y 어떤 이미지 L 레이어 (의 레벨) (X와 Y는 같은 크기)





 $F_{XL} \in C_{nn}(X)$ 깊이 레벨 L에서의 특징 맵(feature map)을 의미



레이어]에 해당하는 콘텐츠의 거리를 정의 :

$$D_C^L(X,Y) = \|F_{XL} - F_{YL}\|^2 = \sum_i (F_{XL}(i) - F_{YL}(i))^2$$



$_{ extstyle LL}$ 의 X 레이어에서 L은 모든 벡터화된 특징 맵(feature map) $oldsymbol{F}_{XL}^{oldsymbol{k}}$

$$G_{XL}(k,l) = \langle F_{XL}^k, F_{XL}^l
angle = \sum_i F_{XL}^k(i).F_{XL}^l(i)$$
 벡터한 곱을 의미

 $m{F}_{XL}^{k}$ $m{F}_{XL}^{l}$ 벡터화(vectorized)되고 연결된(concatenated) 하나의 단일 벡터



레이어]에 해당하는 스타일의 거리를 정의 :

$$D_S^L(X,Y) = ||G_{XL} - G_{YL}||^2 = \sum_{k,l} (G_{XL}(k,l) - G_{YL}(k,l))^2$$

 $D_{\mathcal{C}}(X,\mathcal{C})$ 의 한 번의 최소화를 위해서. 이미지 변수 X 와 대상 콘텐츠-이미지 \mathcal{C}

 $D_S(X,C)$ 와 X와 대상 스타일-이미지S 둘 다 여러 레이어들에 대해서 계산 되야 하고.

우리는 원하는 레이어 각각에서의 거리의 그래디언트를 계산하고 더한다.

: 이 과정의 수식은 복잡하므로 생략 ^^;

$$abla_{extittotal}(X,S,C) = \sum_{L_C} w_{CL_C} . \,
abla_{extitcontent}^{L_C}(X,C) + \sum_{L_S} w_{SL_S} . \,
abla_{extitstyle}^{L_S}(X,S)$$

Lc와 Ls: 콘텐츠와 스타일의 원하는 (임의 상태의) 레이어들을 의미 / w는 가중치를 의미



PyTorch

다행히 pytorch에는 우리가 필요한 모든 함수가 이미 라이브러리로 내장되어 있습니다..!! (진짜 다행,,ㅎㅎ)

실제로 PyTorch를 사용하면 라이브러리의 함수를 사용하는 동안 모든 그래디언트가 자동. 동적으로 계산을 해줍니다..!! ■ torch , torch.nn, numpy (PyTorch로 신경망 처리를 위한 필수 패키지)

Developer Student Clubs

- torch.optim (효율적인 그라디언트 디센트)
- PIL, PIL.Image, matplotlib.pyplot (이미지를 읽고 보여주는 패키지)
- torchvision.transforms (PIL타입의 이미지들을 토치 텐서 형태로 변형해주는 패키지)
- torchvision.models (사전 훈련된 모델들의 학습 또는 읽기 패키지)
- copy (모델들의 깊은 복사를 위한 시스템 패키지)

from __future__ import print_function

import torch import torch.nn as nn import torch.nn.functional as F import torch.optim as optim

from PIL import Image import matplotlib.pyplot as plt

import torchvision.transforms as transforms import torchvision.models as models

import copy

#DeveloperStude

쿠[(CUDA)



컴퓨터에 GPU가 있는 경우, 특히 VGG와 같이 깊은 네트워크를 사용하려는 경우 알고리즘을 CUDA 환경에서 실행



		ConvNet C	onfiguration		
A	A-LRN	В	C	D	Е
11 weight	11 weight	13 weight	16 weight	16 weight	19 weight
layers	layers	layers	layers	layers	layers
	i	nput (224×2)	24 RGB image	e)	
conv3-64	conv3-64	conv3-64	conv3-64	conv3-64 (conv3-64
	LRN	conv3-64	conv3-64	conv3-64	conv3-64
			pool		
conv3-128	conv3-128	conv3-128	conv3-128	conv3-128	conv3-128
		conv3-128	conv3-128	conv3-128	conv3-128
		max	pool		
conv3-256	conv3-256	conv3-256	conv3-256	conv3-256	conv3-256
conv3-256	conv3-256	conv3-256	conv3-256	conv3-256	conv3-256
			conv1-256	conv3-256	conv3-256
					conv3-256
		max	pool		
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
			conv1-512	conv3-512	conv3-512
					conv3-512
		max	pool		
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512
			conv1-512	conv3-512	conv3-512
					conv3-512
			pool		
			4096		
			4096		
			1000		
		soft	-max		

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")

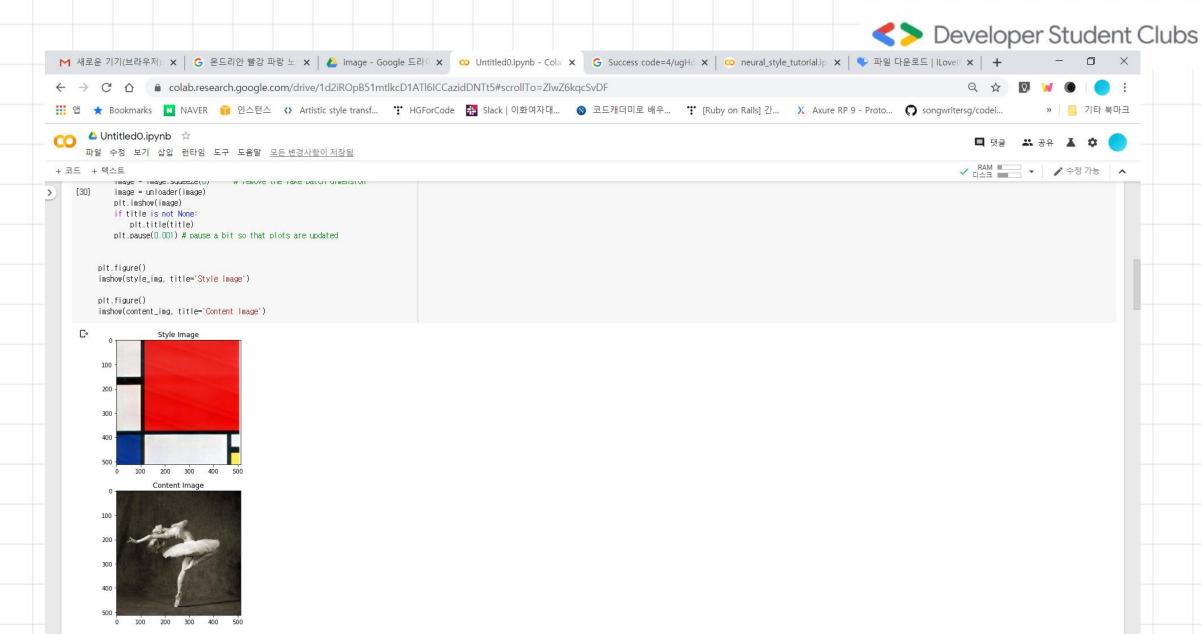
```
# 출력 이미지의 원하는 크기를 정하기.
imsize = 512 if torch.cuda.is_available() else 128 # use small size if no gpu
loader = transforms.Compose([
  transforms.Resize(imsize), # 입력 영상 크기를 맞춤
  transforms.ToTensor()]) # 토치 텐서로 변환
def image_loader(image_name):
  image = Image.open(image_name)
  # 네트워크의 입력 차원을 맞추기 위해 필요한 가짜 배치 차원
  image = loader(image).unsqueeze(0)
  return image.to(device, torch.float)
style_img = image_loader("/content/drive/My Drive/app/image/mondrian.jpg")
content_img = image_loader("/content/drive/My Drive/app/image/dancing.jpg")
assert style_img.size() == content_img.size(), \
  "we need to import style and content images of the same size"
```

- 이미지는 0에서 255 사이의 이미지 픽셀값을 가진다.
- 토치 텐서로 변환하면 O에서 1의 값으로 변환
- 토치 라이브러리의 신경망은 O에서 1의 텐서 이미지로 학습



이미지를 표시하기 위해 plt.imshow 를 이용 / 텐서를 PIL 이미지로 변환

```
unloader = transforms.ToPILImage() # PIL 이미지로 재변환
plt.ion()
def imshow(tensor, title=None):
  image = tensor.cpu().clone() # 텐서의 값에 변화가 적용되지 않도록 텐서를 복제
  image = image.squeeze(0) # 페이크 <mark>배치</mark>차원을 <mark>제거</mark>
  image = unloader(image)
  plt.imshow(image)
  if title is not None:
    plt.title(title)
  plt.pause(0.001) # 그리는 부분이 업데이트 될 수 있게 잠시 정지
plt.figure()
imshow(style_img, title='Style Image')
plt.figure()
imshow(content_img, title='Content Image')
```







콘텐츠 로스는 네트워크에서 X로 입력을 받았을 때 레이어 L에서 특징 맵(feature map) F_{xL} 을 입력으로 가져 와서이 이미지와 콘텐츠 이미지 사이의 가중치 콘텐츠 거리 w_{cL} $D_c^L(X,C)$ 를 반환하는 기능.

```
class ContentLoss(nn.Module):

def __init__(self, target,):
    super(ContentLoss, self).__init__()
# 그라디언트를 동적으로 계산하는 데 사용되는 트리에서 대상 콘텐츠를 '분리'
# :이 값은 변수(variable)가 아니라 명시된 값,
# 그렇지 않으면 기준의 전달 메소드가 오류를 발생
    self.target = target.detach()

def forward(self, input):
    self.loss = F.mse_loss(input, self.target)
    return input
```

스타일 로스

```
def gram_matrix(input):
    a, b, c, d = input.size() # a=배치 크기(=1) # b=특징 맵의 크기
# (c,d)=특징 맵(N=c*d)의 차원

features = input.view(a * b, c * d) # F_XL을 \hat F_XL로 크기 조정

G = torch.mm(features, features.t()) # 그램 곱을 수행

# 그램 행렬의 값을 각 특징 맵의 요소 숫자로 나누는 방식으로 '정규화'를 수행
# 그램 행렬은 선형대수학에서 배우게 됩니다..^^

return G.div(a * b * c * d)
```

특징 맵(feature map) 차원 :math:'N'이 클수록, 그램(Gram) 행렬의 값이 커지는 특징이 있다.



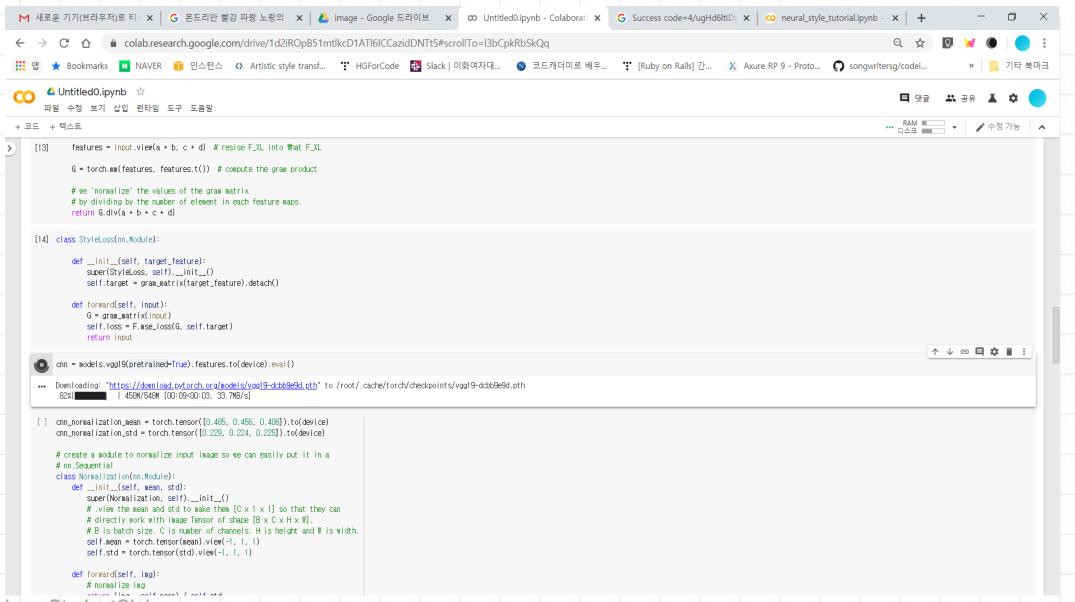
스타일 로스 모듈은 콘텐츠 로스 모듈과 완전히 동일한 방식으로 구현되지만 대 상과 입력 간의 그램 매트릭스의 차이를 비교

```
class StyleLoss(nn.Module):

    def __init__(self, target_feature):
        super(StyleLoss, self).__init__()
        self.target = gram_matrix(target_feature).detach()

    def forward(self, input):
        G = gram_matrix(input)
        self.loss = F.mse_loss(G, self.target)
        return input
```





#DeveloperStudentClubs

뉴럴 네트워크 읽기



PyTorch의 VGG 구현은 두 개의 하위 순차 모듈로 나뉜 모듈 특징(features) 모듈 : 합성곱과 풀링 레이어들을 포함 분류(classifier) 모듈 : fully connected 레이어들을 포함

cnn = models.vgg19(pretrained=True).features.to(device).eval()

```
VGG 네트워크는 평균 = [0.485, 0.456, 0.406] 및 표준편차 = [0.229, 0.224, 0.225]로 정규화 된 각 채널의 이미지에 대해 학습된 모델
cnn_normalization_mean = torch.tensor([0.485, 0.456, 0.406]).to(device)
cnn_normalization_std = torch.tensor([0.229, 0.224, 0.225]).to(device)
# 입력 이미지를 정규화하는 모듈을 만들어 nn.Sequential에 쉽게 입력
# nn.Sequential
class Normalization(nn.Module):
  def __init__(self, mean, std):
    super(Normalization, self).__init__()
    #.view(텐서의 모양을 바꾸는 함수)로 평균과 표준 편차 텐서를 [C x 1 x 1] 형태로 만들어
         # 바로 입력 이미지 텐서의 모양인 [B x C x H x W] 에 연산할 수 있도록 만들
         # B는 배치 크기, C는 채널 값, H는 높이, W는 넓이
         self.mean = torch.tensor(mean).view(-1, 1, 1)
    self.std = torch.tensor(std).view(-1, 1, 1)
  def forward(self, img):
    # img 값 정규화(normalize)
    return (img - self.mean) / self.std
```



알고리즘의 저자인 Len Gatys 가 제안한 방식을 그대로 가져다 쓰면 됨.

```
def get_input_optimizer(input_img):
# 이 줄은 입력은 그레이던트가 필요한 파라미터라는 것을 보여주기 위해 있답니다.
optimizer = optim.LBFGS([input_img.requires_grad_()])
return optimizer
```

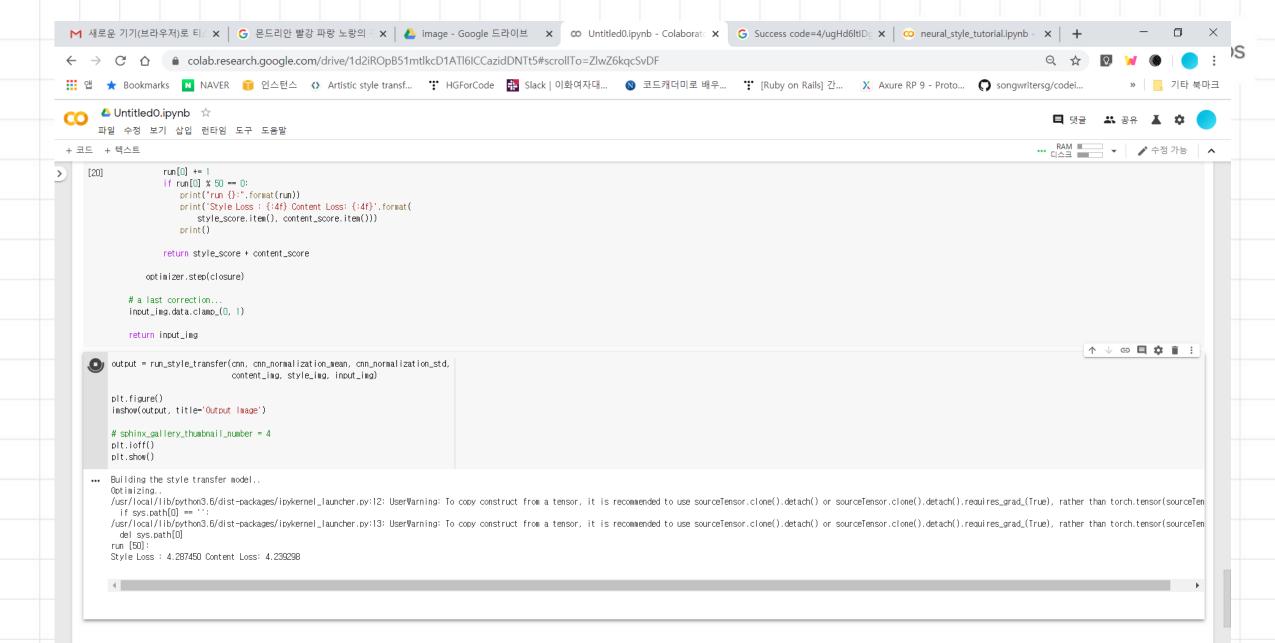
마지막 단계: 경사 하강의 반복. 각 단계에서 우리는 네트워크의 새로운 로스를 계산하기 위해 업데이트 된 입력을 네트워크에 공급해야 한다. 우리는 그래디언트를 동적으로 계산하고 해당 단계를 수행하기 위해 각 손실의 역방향(backward) 메소드를 실행해야 한다. 옵티마이저는 인수로서 "클로저(closure)"를 필요: 즉, 모델을 재평가하고 로스를 반환 하는 함수.

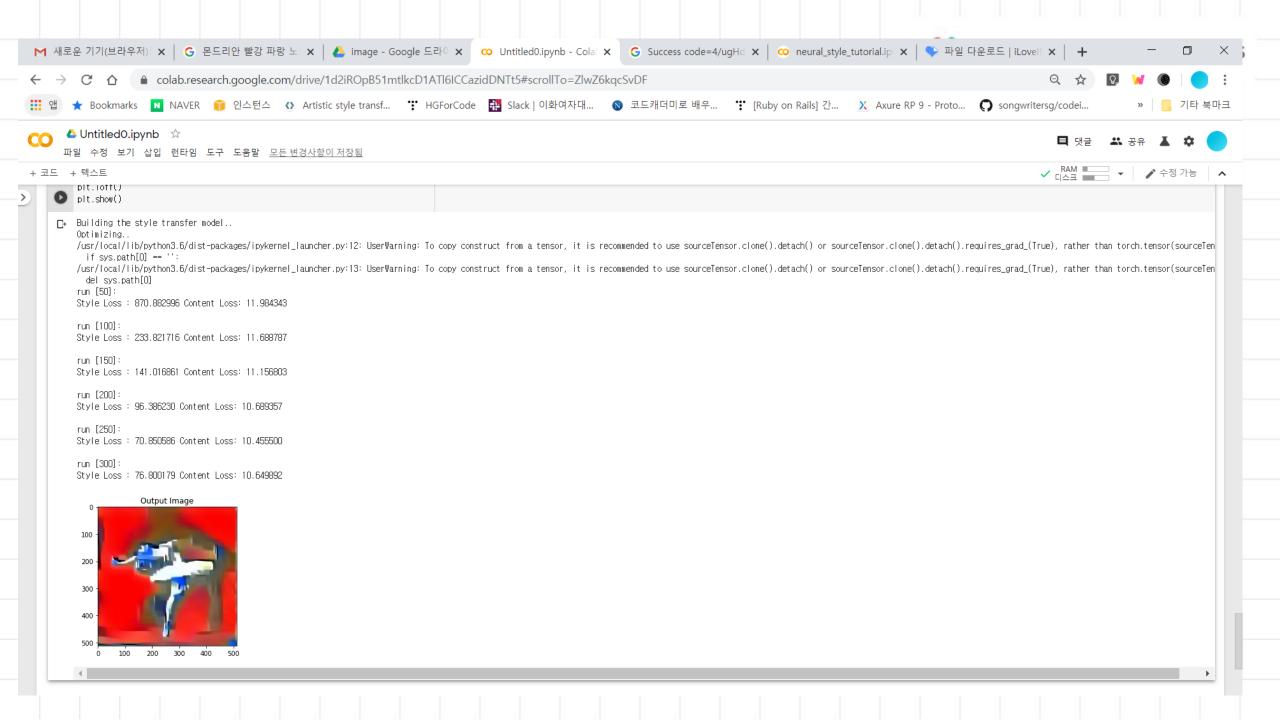
최적화 된 이미지는 O 과 1 사이에 머물지 않고 무한대 사이의 값을 가질 수도 있다.
→ 따라서 입력 이미지가 올바른 범위의 값을 유지할 수 있도록 제약 조건 하에서 최적화를 수행
→ closure()

```
def run_style_transfer(cnn, normalization_mean, normalization_std,
            content_img, style_img, input_img, num_steps=300,
            style_weight=1000000, content_weight=1):
def closure():
      # 입력 이미지의 업데이트된 값들을 보정
      input_img.data.clamp_(0, 1)
# 마지막 보정...
  input_img.data.clamp_(0, 1)
  return input_img
```

마지막으로, 알고리즘을 실행!!







감사합니다 o(*'▽'*)/☆°'

#DeveloperStudentClubs